

第九章 回归分析

主要内容

§ 9-1 回归分析的基本概念

§ 9-2 一元线性回归分析

§ 9-3 两个变量都有误差时回归分析

§ 9-4 其他回归问题简介

§ 9-1 回归分析的基本概念

一、变量之间的关系

变量之间的关系可分为两种类型。

函数关系

相关关系

函数和相关虽然是两种不同类型的变量关系，但是它们之间并无严格的界限。

1. 函数关系

函数关系是确定性关系。在这种关系中，变量间是一一准确对应的。

数学分析和物理学中的大多数公式都属于这种关系。例如一定质量 m 的物体受力 F 与所产生的加速度 a 的关系。

2. 相关关系

$$F = m a$$

在实际工作中，绝大多数情况下，变量之间的关系不那么简单，往往在影响结果的已知因素之外，还存在1个或多个对结果产生影响的未知因素。

变量间这种具有密切关联而又**不能**由某一个或某一些变量**唯一确定**另外一个变量的关系称为变量间的**相关关系或统计关系**。

3. 两种不同类型变量的关系

函数关系是完全探明的不存在其他影响因素的情况下表达变量之间内在规律的关系。

相关关系是存在着若干未探明的影响因素的关系。

二者并不存在严格区别。

若控制未探明因素使其不变，或者将未探明因素引入到函数关系式之中，相关关系就变为函数关系。反之，本来为函数关系的变量之间，若由某种原因引入了未探明影响因素(例如对某量控制存在误差)，则对应关系就会由函数关系变为相关关系。

如上述 $F=ma$ ，即使 m 不变，实测的 F 和 a 之间也会变得与公式计算结果不完全相符，即 F 和 a 的实验数据由函数关系变成了相关关系。由此也可知，实验所得的对应量之间，一般存在相关关系，而不是函数关系。

二、回归与回归分析的概念

1. 回归

从存在相关关系或函数关系的若干组自变量与因变量值的对应数据出发求出反应自变量与因变量关系的未知解析表达式的过程称为**回归**。

2. 回归分析

回归分析是分析回归所得到的解析表达式的可靠性的过程，是处理变量之间相关关系的一种数理统计方法。

回归得出的解析表达式常称为**回归方程**。回归方程能否表达有关数据的内在规律性，还需要进行科学分析。

回归是自然科学研究中探明未知规律，把未知的内在规律性表达出来的重要方法。该方法常用于建立变量之间的经验公式或者实验定律。

三、回归分析在本领域的应用

回归分析和相关分析是研究相关关系的一种数学工具。

回归分析则是应用数学方法对大量观测数据加以处理，从而求出非确定性关系的变量之间的关系规律性，并用数学关系式表达出来。

在回归分析中，假定因变量的误差呈正态分布，而对自变量的误差分布并无要求，也就是只考虑在自变量保持一系列定值时，因变量这个随机变量是如何变化的。

回归分析能解决的问题

利用回归分析能解决的问题可归纳为下述五个内容

①**经验公式** 根据实验数据，求取变量之间相关的定量关系式；

②**可信性检验** 对求得经验公式的可信性进行统计检验；

③**预报和控制** 利用求得的经验公式根据取得或确定的数值，预测或控制其它变量的取值，并对预报和控制的结果，进行可信程度的评定；

④**因素分析** 从影响某一变量的许多变量中，判断哪些变量影响显著；哪些变量不显著；哪些变量没有影响；

⑤**实验方案的设计** 根据实验的目的和对实验结果的精度要求，考虑回归分析对数据的要求，主动的安排实验方案，使设计出的实验方案，能够用较少的实验次数，获取最大的信息量，并能使获得的实验数据具有较好的统计性质，便于回归分析的数据处理。

五、回归分析与最小二乘的关系

相同点：

回归分析是基于最小二乘原理的方法，回归方程的求解与最小二乘方法基本相似。

不同点：

最小二乘方法是对数据拟合表达式——经验公式的求解，并只对求得的待求参数估计量精度进行评价，不对所拟合的经验公式的整体精度进行分析和检验；

回归分析在求解回归方程系数后，需进一步对所得的回归方程与实际研究的事物规律性的符合程度进行分析与检验。

六、本章主要解决的问题

本章主要解决以下几方面的问题：

①从一组数据出发，确定这些变量之间的数学表达式——一元线性回归方程或经验公式。

②对回归方程的可信程度进行统计检验。

③进行因素分析，例如对于共同影响一个变量的许多变量(因素)中，找出哪些是重要因素，哪些是次要因素。

§ 9-2 一元线性回归

一元回归分析是回归分析中最简单的一种。它所研究的对象是两个变量之间的相关关系。它又分为一元线性回归与一元非线性回归。

假如两个变量之间的关系是线性的就称为一元线性回归，这就是工程上和科研中常遇到的直线拟合问题。


问题的提出

例1，测量某导线在一定温度 x 下的电阻值 y 得如下结果：

$x/^{\circ}\text{C}$	19.1	25.0	30.1	36.0	40.0	46.5	50.0
y/Ω	76.30	77.80	79.75	80.80	82.35	83.90	85.10

试找出它们之间的内在关系。 ?

为了研究电阻 y 与温度 x 之间的关系，把数据点在坐标纸上。这种图叫散点图，从散点图可以看出，电阻 y 与温度 x 大致成线性关系。因此，我们假设 x 与 y 之间的内在关系是一条直线，这些点与直线的偏离是试验过程中其他一些随机因素的影响而引起的。



现在的问题？

现在的问题是如何找出这条直线？

假设温度值 x 无误差，则可建立如下方程

$$y_t = \beta_0 + \beta x_t + \varepsilon_t, \quad t = 1, 2, \dots, N \quad (9-1)$$

式中， $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_N$ 分别表示其他随机因素对电阻测值 y 的影响总和。 β_0 、 β ，回归系数。

现在的问题又转换为如何找出 β_0 和 β 的最佳估计值。

可以用最小二乘法来估计参数 β_0 和 β

一、一元线性回归方程

(一) 回归方程的求法

我们可以用最小二乘法来估计参数 β_0 和 β 。

设 b_0 和 b 分别是参数 β_0 和 β 的最小二乘估计，于是得到一元线性回归的回归方程

$$\hat{y} = b_0 + bx \quad (9-2)$$

式中的 b_0 、 b 是回归方程的回归系数。

残余误差方程

对每一个 x_t 由方程(9—2)可以确定一个回归值 $\hat{y}$

$=b_0+bx_t$ 。实际测得值 y_t 与这个回归值之差就是残余误差 v_t : 即

$$v_t = y_t - \hat{y} = y_t - (b_0 + bx_t) \quad (9-3)$$

$$t=1,2,\dots,N$$

根据最小二乘原理应使

$$R = \sum_{i=1}^N v_t^2 = \sum_{i=1}^N (y_t - b_0 - bx_t)^2 = \min$$

故有

$$\left\{ \begin{array}{l} \frac{\partial R}{\partial b_0} = -2 \sum_{i=t}^N (y_t - b_0 - bx_t) \\ \frac{\partial R}{\partial b} = -2 \sum_{t=1}^N (y_i - b_0 - bx_t)x_t \end{array} \right.$$

残余误差方程式的矩阵形式

• 令

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} \quad X = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_N \end{bmatrix} \quad B = \begin{bmatrix} b_0 \\ b \end{bmatrix} \quad V = \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_N \end{bmatrix}$$

则残余误差方程式的矩阵形式可表示为

$$Y - XB = V \quad (9-4)$$

假定测得值 y_i 的精度相等，根据最小二乘原理，回归系数的矩阵解为

$$B = (X^T X)^{-1} X^T Y = C^{-1} X^T Y \quad (9-5)$$

式中

$$C = X^T X$$

式(6-5)中的有关矩阵计算

$$X^T X = \begin{bmatrix} N & \sum_{t=1}^N X_t \\ \sum_{t=1}^N X_t & \sum_{t=1}^N X_t^2 \end{bmatrix} \quad \Rightarrow \quad C^{-1} = (X^T X)^{-1}$$

$$X^T Y = \begin{bmatrix} \sum_{t=1}^N y_t \\ \sum_{t=1}^N X_t y_t \end{bmatrix}$$

回归系数的解

$$b = \frac{N \sum_{t=1}^N x_t y_t - \left(\sum_{t=1}^N x_t \right) \left(\sum_{t=1}^N y_t \right)}{N \sum_{t=1}^N x_t^2 - \left(\sum_{t=1}^N x_t \right)^2} \quad (9-7)$$

$$b_0 = \frac{\left(\sum_{t=1}^N x_t^2 \right) \left(\sum_{t=1}^N y_t \right) - \left(\sum_{t=1}^N x_t \right) \left(\sum_{t=1}^N x_t y_t \right)}{N \sum_{t=1}^N x_t^2 - \left(\sum_{t=1}^N x_t \right)^2} \quad (9-8)$$

由式(9—9)、式(9—8)求回归方程的回归系数具体计算，通常是列表进行。

例如，例6-1求回归方程的回归系数具体计算可列表如下

序 号	$x/^{\circ}\text{C}$	y/Ω	$x^2/^{\circ}\text{C}^2$	y^2/Ω^2	$xy/(\Omega\cdot^{\circ}\text{C})$
1	19.1	76.30	364.81	5821.690	1457.330
2	25.0	77.80	625.00	6052.840	1945.000
3	30.1	79.75	906.01	6360.062	2400.475
4	36.0	80.80	1296.00	6528.840	2908.800
5	40.0	82.35	1600.00	6781.522	3294.000
6	46.5	83.90	2162.25	7039.210	3901.350
7	50.0	85.10	2500.00	7242.010	4255.000
Σ	246.7	566.00	9454.07	45825.974	20161.955

通过计算，前例的回归方程为

$$y = 70.90\Omega + (0.2824\Omega/^{\circ}\text{C})x$$

定义相关的统计变量

x的算术平均值

$$\bar{x} = \frac{1}{N} \sum_{t=1}^N x_t \quad (9-9)$$

y的算术平均值

$$\bar{y} = \frac{1}{N} \sum_{t=1}^N y_t \quad (9-10)$$

x的离差平方和

$$l_{xx} = \sum_{t=1}^N (x_t - \bar{x})^2 = \sum_{t=1}^N x_t^2 - \frac{1}{N} (\sum_{t=1}^N x_t)^2 \quad (9-11)$$

xy的协方差和

$$l_{xy} = \sum_{t=1}^N (x_t - \bar{x})(y_t - \bar{y}) = \sum_{t=1}^N x_t y_t - \frac{1}{N} \sum_{t=1}^N x_t \sum_{t=1}^N y_t \quad (9-12)$$

y的离差平方和

$$l_{yy} = \sum_{t=1}^N (y_t - \bar{y})^2 = \sum_{t=1}^N y_t^2 - \frac{1}{N} (\sum_{t=1}^N y_t)^2 \quad (9-13)$$

回归直线的另一种形式

利用上述统计量的计算式，可得回归系数统计量的计算式

$$b_0 = \bar{y} - b\bar{x}$$

将 $b_0 = \bar{y} - b\bar{x}$ 代入式（9-2），则可得回归直线的另一种形式

$$\hat{y} - \bar{y} = b(x - \bar{x}) \quad (9—14)$$

由此可见，回归直线式(9—2)通过点($\bar{x}, \bar{y}$)，明确这一点对回归直线的作图是有帮助的。

(二) 回归方程的稳定性分析

回归方程的稳定性是指回归值 $\hat{y}$ 的波动大小，波动愈小，回归方程的稳定性愈好。

和对待一般的估计值一样， $\hat{y}$ 的波动大小用 $\hat{y}$ 的标准差 $\sigma_{\hat{y}}$ 来表示。

根据随机误差传递公式及回归方程(9—2)有

$$\sigma_{\hat{y}}^2 = \sigma_{b_0}^2 + x^2 \sigma_b^2 + 2x \sigma_{b_0 b} \quad (9—15)$$

式中

σ_{b_0} 、 σ_b —— b_0 、 b 的标准差；
 $\sigma_{b_0 b}$ —— b_0 和 b 的协方差

有关证明

设 σ 为测量数据 y 的残余标准差，可以证明

$$\sigma_{b_0}^2 = \frac{\sum_{t=1}^N x_t^2}{N \sum_{t=1}^N x_t^2 - \left(\sum_{t=1}^N x_t \right)^2} \sigma^2 = \left(\frac{1}{N} + \frac{\bar{x}^2}{l_{xx}} \right) \sigma^2 \quad (9-16)$$

$$\sigma_b^2 = \frac{N}{N \sum_{t=1}^N x_t^2 - \left(\sum_{t=1}^N x_t \right)^2} \sigma^2 = \frac{\sigma^2}{l_{xx}} \quad (9-17)$$

$$\sigma_{b_0 b} = \frac{- \sum_{t=1}^N x_t}{N \sum_{t=1}^N x_t^2 - \left(\sum_{t=1}^N x_t \right)^2} \sigma^2 = - \frac{\bar{x}}{l_{xx}} \sigma^2 \quad (9-18)$$

回归值 $\hat{y}$ 的方差与标准差

根据（9-16）、（9-17）、（9-18）有

$$\sigma_y^2 = \left(\frac{1}{N} + \frac{\bar{x}^2}{l_{xx}} \right) \sigma^2 + x^2 \frac{\sigma^2}{l_{xx}} - 2x \frac{\bar{x}}{l_{xx}} \sigma^2 = \left(\frac{1}{N} + \frac{(x - \bar{x})^2}{l_{xx}} \right) \sigma^2 \quad (9-19)$$

$$\sigma_y = \sigma \sqrt{\frac{1}{N} + \frac{(x - \bar{x})^2}{l_{xx}}} \quad (9-20)$$

由式(9—20)可见，回归值的波动大小不仅与残余标准差 σ 有关，而且还取决于试验次数 N 及自变量 x 的取值范围。 N 愈大， x 的取值范围愈小，回归值 $\hat{y}$ 的精度愈高。

二、回归方程的方差分析及显著性检验

回归直线式求出来了，但它是否有实际意义呢?这里有两个问题需要解决：

其一，需要对回归方程进行显著性检验，以便知道这条直线是否基本上符合 y 与 x 之间的客观规律。

其二，由于 x 与 y 之间是相关关系，知道了 x 值，并不能精确地知道 y 值。那么，用回归方程，根据自变量 x 值预报(或控制)因变量 y 值，其效果如何?这就是回归直线的预报精度问题。

为此，必须对回归问题作进一步分析。

常用的是方差分析法

(一) 回归问题的方差分析与计算

1. 方差分析

观测值 $y_1, y_2, \dots, y_N$ 之间的差异(称变差), 是由两个方面原因引起的:

- ①自变量 x 取值的不同;
- ②其他因素(包括试验误差)的影响。

为了对回归方程进行检验, 首先必须把它们所引起的变差从 y 的总变差中分解出来。

总的离差平方和

N个观测值之间的变差，可用观测值 y 与其算术平均值的离差平方和来表示，称为总的离差平方和，记作

$$S = \sum_{t=1}^N (y_t - \bar{y})^2 = l_{yy} \quad (9-21)$$

因为

$$\begin{aligned} S &= \sum_{t=1}^N (y_t - \bar{y})^2 = \sum_{t=1}^N [(y_t - \hat{y}_t) + (\hat{y}_t - \bar{y})]^2 \\ &= \sum_{t=1}^N (\hat{y}_t - \bar{y})^2 + \sum_{t=1}^N (y_t - \hat{y}_t)^2 + 2 \sum_{t=1}^N (y_t - \hat{y}_t)(\hat{y}_t - \bar{y}) \end{aligned}$$

可以证明，交叉项

$$\sum_{i=1}^n (y_t - \hat{y}_t)(\hat{y}_t - \bar{y}) = 0$$

证明如下

由式（9-14）知，

将其代入交叉项，得

$$\sum_{i=1}^N (y_t - \hat{y}_t)(\hat{y}_t - \bar{y}) = \sum_{i=1}^N [y_t - (b_0 + bx_t)][(b_0 + bx_t) - \bar{y}]$$

再将 $b_0 = \bar{y} - b\bar{x}$ 代入上式，得

$$\sum_{i=1}^N (y_t - \hat{y}_t)(\hat{y}_t - \bar{y}) = \sum_{i=1}^N [y_t - (\bar{y} - b\bar{x} + bx_t)][(\bar{y} - b\bar{x} + bx_t) - \bar{y}]$$

$$= \sum_{i=1}^N b[(y_t - \bar{y}) - b(x_t - \bar{x})](x_t - \bar{x})$$

$$= b(l_{xy} - bl_{xx}) = 0$$

故有

$$\sum_{i=1}^n (y_t - \hat{y}_t)(\hat{y}_t - \bar{y}) = 0$$

证毕

总的离差平方和的分解式

因此总的离差平方和可以分解为两个部分，即

$$S = \sum_{i=1}^N (y_i - \bar{y})^2 = \sum_{i=1}^N (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (9-23)$$

或者写成

$$S = U + Q \quad (9-24)$$

式中


$$U = \sum_{i=1}^N (\hat{y}_i - \bar{y})^2 \quad (9-25)$$

$$Q = \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (9-26)$$

U称为回归平方和；

Q称为残余平方和；

S称为离差平方和。



由图中可以看出，如果残差平方和很小，则（回归平方和） / （总离差平方和）将接近于1。这时，所有的观测点都靠近或落在回归线上，这就表明回归直线的精度较高。

U和 Q的意义

回归平方和U，它反映了在y总的变差中由于x和y的线性关系而引起y变化的部分。因此回归平方和U也就是考虑了x与y的线性关系部分在总的离差平方和S中所占的成分，以便从数量上与Q值相区分。

残余平方和Q，即所有观测点距回归直线的残余误差的平方和。它是除了x对y的线性影之外的一切因素(包括试验误差、x对y的非线性影内以及其它未加控制的因素)对y的变差作用，这部分的变差是仅考虑x与y的线性关系所不能减少的部分。

这样，通过平方和分解式(9—23)就把对N个观测值的两种影响从数量上区分开来。

2. S、U、Q的计算式

U和Q的具体计算值可按下式计算：

$$\begin{aligned} U &= \sum_{i=1}^N (\hat{y}_i - \bar{y})^2 = \sum_{i=1}^N (b_0 + bx_i - b_0 - b\bar{x})^2 \\ &= b^2 \sum_{i=1}^N (x_i - \bar{x})^2 = b \sum_{i=1}^N (x_i - \bar{x})(\hat{y}_i - \bar{y}) = bl_{xy} \end{aligned} \quad (9-27)$$

$$Q = \sum_{i=1}^N (y_i - \hat{y}_i)^2 = S - U = l_{yy} - bl_{xy} \quad (9-28)$$

因此，在计算S、U、Q时完全可以利用回归系数计算过程中的一些结果。

3. 方差的自由度

作为统计变量的每个平方和都有一个称为“自由度”的数据跟它相联系。如果总的离差平方和是由N项组成，其自由度就是N—1。如果一个平方和是由几部分相互独立的平方和组成，则总的自由度等于各部分自由度之和。

总的离差平方和的自由度 v_S ，也等于回归平方和的自由度 v_U 与残余平方和的自由度 v_Q 之和，即

$$v_S = v_U + v_Q \quad (9-29)$$

在回归问题中

$$v_S = N - 1$$

v_U 对应于自变量的个数，因此在一元线性回归问题中 $v_U = 1$ 。

因此，有 $v_Q = N - 2$

(二) 回归方程显著性检验

由回归平方和与残余平方和的意义可知，一个回归方程是否显著，也就是y与x的线性关系是否密切，取决于U及Q的大小。

U愈大 Q愈小 说明y与x的线性关系愈密切。

回归方程显著性检验通常采用F检验法，因此要计算统计量F

$$F = \frac{U/\nu_U}{Q/\nu_Q} \quad (9-30)$$

对一元线性回归

$$F = \frac{U/1}{Q/(N-2)} \quad (9-31)$$

F检验

检验时，一般需查出F分布表中对三种不同显著性水平 $F_{0.01}(v_1, v_2)$ 、 $F_{0.05}(v_1, v_2)$ 和 $F_{0.1}(v_1, v_2)$ 。

比较F和 F_{α} (临界值)，若 $F > F_{\alpha}$ ，则说明回归方程在 α 概率水平上显著。

一般来说，若

$$F \geq F_{0.01}$$

高度显著

$$F_{0.05} \leq F \leq F_{0.01}$$

显著

$$F_{0.10} \leq F \leq F_{0.05}$$

基本显著

$$F < F_{0.10}$$

不显著

若检验结果为不显著，则认为y-x回归关系不成立。对上述一元线性关系来说，不显著意味着x的高次项不可忽略，或者还存在影响y值的其他不可忽略的自变量，或数据的随机误差太大。

(三) 残余方差与残余标准差

用残差平方和Q除以它的自由度 v_Q 之商，称为残余方差，即

$$\sigma^2 = \frac{Q}{N-2} \quad (9-32)$$

残余标准差

$$\sigma = \sqrt{\frac{Q}{N-2}} \quad (9-33)$$

σ 表示回归所依据的数据点 (x_t, y_t) 总体上偏离回归直线 $y=b_0+bx$ 的程度。

σ 越大，偏离越大，反之偏离越小。

σ 越小，回归方程越好，回归方程的精度越高。

(四) 方差分析表

作方差分析时列表进行眉目清楚，简便易行，减少错误。上述方差分析的过程可列在如下表所示的方差分析表中

来 源	平方和	自由度	方 差	F	显著性
回 归	$U = bl_{xy}$	1		$F = \frac{U/1}{Q/(N-2)}$	—
残 余	$Q = l_{yy} - bl_{xy}$	$N - 2$	$\sigma^2 = Q/(N - 2)$		—
总 计	$S = l_{yy}$	$N - 1$	—	—	—

例如，对在例6—1电阻对温度的回归方差分析列表

来 源	平方和/ Ω^2	自由度	方差/ Ω^2	F	显著性
回 归	60.574	1	—	1.18×10^3	$\alpha = 0.01$
残 余	0.257	5	0.0514	—	—
总 计	60.831	6	—	—	—

显著性一栏中的 $\alpha = 0.01$ ，表明前面所得的回归方程(6-15)在 $\alpha = 0.01$ 水平上显著，即可信赖程度为99%以上，这是高度显著的。

小 结

利用回归方程，可以在一定显著性水平 α 上，确定与 x 相对应的 y 的取值范围。

反之若要求观测值 y 在一定的范围内取值，利用回归方程可以确定自变量 x 的控制范围。

三、重复试验时的方差分析与F检验

上述用残余平方和检验回归平方和即使得到回归方程“显著”的判断，只说明相对于 x 的高次项和其他量影响及误差因素而言， x 的一次项对 y 的影响是主要的，但并不说明除 x 一次项之外， x 高次项及其他量影响与误差项的影响哪个更大。也就是说，不能判明 x 高次项或其他量的影响是否存在。

为了判明这一点必须进行重复实验。即必须对对应同一 x ，对 y 值进行多次重复测量。

1. 重复试验时的方差分析

设取N个试验点，每个试验点都重复m次试验．此时各种平方和及其相应的自由度可按下列各式计算

$$S = U + Q_L + Q_E \quad \nu_S = \nu_U + \nu_L + \nu_E$$

$$S = \sum_{t=1}^n \sum_{i=1}^m (y_{ti} - \bar{y})^2 \quad \nu_S = nm - 1$$

离差平方和

$$U = m \sum_{t=1}^n (\hat{y}_t - \bar{y})^2 \quad \nu_U = 1$$

回归平方和

$$Q_E = \sum_{t=1}^n \sum_{i=1}^m (y_{ti} - \bar{y}_t)^2 \quad \nu_{Q_E} = n(m - 1)$$

误差平方和

$$Q_L = m \sum_{t=1}^n (\bar{y}_t - \hat{y}_t)^2 \quad \nu_{Q_L} = n - 2$$

失拟平方和

各种平方和的计算式

若利用回归计算结果，则上述各量计算式为

$$\begin{aligned}U &= mbl_{xy} \\Q_L &= ml_{yy} - U \\Q_E &= \sum_{t=1}^n \sum_{i=1}^m (y_{ti} - \bar{y}_t)^2 \\S &= U + Q_L + Q_E\end{aligned}$$

失拟平方和 Q_L 或失拟方差反映了拟合误差，通常称为**模型误差**。

U 是表征 x 一次项对 y 影响大小的量,称为**回归平方和**

Q_E 是表征实验误差大小的量，称为**误差平方和**

Q_L 是表征 x 高次项影响（非线性因素影响）或其他量影响(其他未加控制的系统因素等)大小的量，可称为**失拟平方和**。

重复试验的意义

(1) 在一般情况下，重复试验可将误差平方和与失拟平方和从残余平方和中分离出来，这对统计分析是有好处的。

(2) 在精密测试仪器中，通常失拟平方和及误差平方和分别与仪器的原理误差(定标误差、非线性误差)及仪器的随机误差相对应。

应用这种方法分析传感器或非电量电测仪器及其他类似需要变换参量的测量仪器的精度，可以将系统误差与随机误差分离开来，并可用回归分析方法进一步找出仪器的误差方程，从而可以对仪器的误差进行修正。不需要对仪器作任何改进，只是通过数据处理，对仪器的系统误差进行修正，就可使仪器的精度明显提高，这是提高仪器精度的一种颇为有效的方法。

小 结

通过重复试验的回归分析对了解仪器的误差来源和提高仪器的精度是有益的。如果没有条件做重复试验，只能用残余平方和对回归平方和按式(6—30)进行F检验，也可大致说明回归效果的好坏。

实际应用中经常把这种检验结果显著与不显著说成拟合得好与坏。 **但需要注意**，一个方程拟合得好的真正含义应该是失拟平方和相对于误差平方和来讲是不显著的。

2. 重复试验时的F检验

进行F检验须先求出

$$F_1 = \frac{Q_L/\nu_{Q_L}}{Q_E/\nu_{Q_E}}$$

$$F_2 = \frac{U/\nu_U}{Q_L/\nu_{Q_E}}$$

$$F = \frac{U}{(Q_E + Q_L)/(\nu_{Q_E} + \nu_{Q_L})}$$

然后，分别比较F、F₁和F₂与临界值F_α的关系，检验是否显著。

检验结果分析

(1) 用误差平方和对失拟平方和进行F检验——**F1检验**

F1检验可以确定回归方程拟合得好坏

F1显著 说明相对于实验随机误差而言，系统性的影响因素对 y 值的影响不可忽略，这时有如下几种可能：

- ① 影响 y 的除 x 外，至少还有一个不可忽略的因素。
- ② y 和 x 是曲线关系。
- ③ y 和 x 无关。

总之，所选择的一元线性回归这个数学模型与实际情况不符合，说明该直线拟合得并不好，另引入 x 的高次项或其他量修改回归方程，可能得到更好的 y - x 表达式。

F1检验结果不显著时的进一步分析

如果F1检验结果不显著，说明非线性误差(相对于试验误差讲)很小，或者基本上是由试验误差等随机因素引起的。于是可把失拟平方和 Q_L 与误差平方和 Q_E 合并，对回归平方和进行F检验，如果第二次F检验结果显著，说明一元回归方程拟合得好。

如果F1检验结果不显著，对于给定的显著性水平，当F和F2也不显著，那么这时有两种可能：

- ①没有什么因素对y有系统的影响。
- ②试验误差过大。

当然所求的回归方程不理想。

(2) 用误差平方和对回归平方和进行F检验—— F_2 检验

F_2 显著的意义是相对于实验的随机误差对y值的影响而言，x一次项的影响很大，用线性表达式 $y=b_0+bx$ 基本上可以表达y-x关系。

(3) 用残余平方和对回归平方和进行F检验——F检验

F显著的意义则是相对于系统性的影响因素和实验的随机误差对y的综合影响而言，x一次项对y的影响很大。这说明y-x关系基本可以用直线关系方程表示。

F1显著而F2和F也显著时的进一步分析

F_1 检验结果显著，虽然相对于试验误差来讲，此方程不能说拟合得很好，但并不能说明回归方程就没有用了。

F_1 显著而F也显著时，说明还存在x高次项或其他量对y的影响(系统性的影响因素)。 F_1 显著水平说明了该影响的大小， F_1 显著水平越高，系统性的影响因素的影响越大。

F_1 显著而 F_2 和F也显著，说明试验误差和残余误差都很小，只要残余标准差 σ 小于仪器所要求的精度参数，还是可以使用此方程对该仪器进行定标。

当然，如有必要，可进一步查明原因，重作回归方程。

3. 重复试验方差分析表

重复进行试验作方差分析检验，列表进行眉目清楚不易出错。所列表格可称为重复试验方差分析表。

重复试验方差分析表

来源	平方和	自由度	方差	F		显著性
回归	$U = mbl_{xy}$	$\nu_U = 1$			$F_1 = \frac{Q_L/\nu_{Q_L}}{Q_E/\nu_{Q_E}}$	—
失拟	$Q_L = ml_{yy} - U$	$\nu_{Q_L} = n - 2$	$\sigma_L^2 = Q_L/\nu_{Q_L}$			
误差	$Q_E = \sum_{i=1}^n \sum_{t=1}^m (y_{it} - \bar{y}_i)^2$	$\nu_{Q_E} = n(m - 1)$	$\sigma_E^2 = Q_E/\nu_{Q_E}$		$F_2 = \frac{U/\nu_U}{Q_E/\nu_{Q_E}}$	—
残差	$Q = Q_E + Q_L$	$\nu_Q = \nu_{Q_L} + \nu_{Q_E}$	$\sigma^2 = Q/\nu_Q$		$F = \frac{U/\nu_U}{Q/\nu_Q}$	—

应用举例

用标准压力计对某固体压力传感器进行检定，检定的压力传感器所受标准压力与输出电压的测试数据如表。表中 x_i 为压力数据， y_i 为输出电压数据， $\bar{y}_i$ 为四次读数的算术平均值。

试用直线标定该压力传感器的电压—压力关系，对仪器定标，并分析仪器的误差。

序 号	$x_i/(N \cdot cm^{-2})$	y_i/mV				$\bar{y}_i/mV$
		升 压	降 压	升 压	降 压	
1	0	2.78	2.80	2.80	2.86	2.81
2	1	9.70	9.76	9.78	9.78	9.755
3	2	16.60	16.71	16.70	16.76	16.692 5
4	3	23.54	23.56	23.58	23.71	23.597 5
5	4	30.44	30.51	30.54	30.64	30.532 5
6	5	37.35	37.45	37.42	37.50	37.43
7	6	44.28	44.35	44.30	44.38	44.327 5
8	7	51.19	51.25	51.18	51.25	51.217 5
9	8	58.06	58.08	58.12	58.14	58.1
10	9	64.92	64.96	64.94	65.00	64.955
11	10	71.73	71.73	71.75	71.75	71.74

解：

1.确定回归方程的函数形式

仪器要求线性定标，故应拟合一条回归直线。
令回归直线表示为

$$y = b_0 + bx$$

2. 计算出用最小二乘法计算的 b_0 和 b 所需正规方程的各系数

根据测量数据表中的数据，用表格方式计算出用最小二乘法计算的 b_0 和 b 所需正规方程的各系数。

见计算表1

计算表1 （正规方程式系数计算表）

序号	$x/(\text{N} \cdot \text{cm}^{-2})$	y/mV	$x^2/(\text{N} \cdot \text{cm}^{-2})^2$	$y^2/(\text{mV})^2$	$xy/(\text{mV} \cdot \text{N} \cdot \text{cm}^{-2})$
1	0	2.810 0	0	7.896 1	0
2	1	9.755 0	1	95.160 0	9.750 0
3	2	16.692 5	4	278.639 6	33.385 0
4	3	23.597 5	9	556.842 0	70.792 5
5	4	30.532 5	16	932.233 6	122.130 0
6	5	37.430 0	25	1 401.004 9	187.150 0
7	6	44.327 5	36	1 964.927 3	265.965 0
8	7	51.217 5	49	2 623.232 3	358.522 5
9	8	58.100 0	64	3 375.610 0	464.800 0
10	9	64.955 0	81	4 219.152 0	584.595 0
11	10	71.740 0	100	5 146.627 6	717.400 0
Σ	55	411.157 5	385	26 601.325 4	2 814.495 0

3. 计算 b_0 和 b 的结果

应用计算表1的结果，分别计算有关统计量，最后计算出回归系数 b_0 和 b 的结果。见计算表2

b_0 、 b 的计算过程及结果表

$\sum_{i=1}^N x_i = 55 \text{ N/cm}^2$ $\bar{x} = 5 \text{ N/cm}^2$ $\sum_{i=1}^N x_i^2 = 385 (\text{N/cm}^2)^2$ $\left(\sum_{i=1}^N x_i \right)^2 / N = 275 (\text{N/cm}^2)^2$ $l_{xx} = \sum_{i=1}^N x_i^2 - \left(\sum_{i=1}^N x_i \right)^2 / N$ $= 110 (\text{N/cm}^2)^2$	$\sum_{i=1}^N y_i = 411.1575 \text{ mV}$ $\bar{y} = 37.3780 \text{ mV}$ $\sum_{i=1}^N y_i^2 = 20601.3254 \text{ mV}^2$ $\left(\sum_{i=1}^N y_i \right)^2 / N = 15368.2264 \text{ mV}^2$ $l_{yy} = \sum_{i=1}^N y_i^2 - \left(\sum_{i=1}^N y_i \right)^2 / N$ $= 5233.0990 \text{ mV}^2$ $b = \frac{l_{xy}}{l_{xx}} = 6.89734 \text{ mV} / (\text{N} \cdot \text{cm}^{-2})$ $b_0 = \bar{y} - b\bar{x} = 2.8913 \text{ mV}$ $\hat{y} = 2.8913 \text{ mV} + [6.89734 \text{ mV} / (\text{N} \cdot \text{cm}^{-2})]x$	$N = 11$ $\sum_{i=1}^N x_i y_i = 2814.4950 \text{ mV} \cdot \text{N/cm}^2$ $\left(\sum_{i=1}^N x_i \right) \left(\sum_{i=1}^N y_i \right) / N = 2055.7875 \text{ mV} \cdot \text{N/cm}^2$ $l_{xy} = \sum_{i=1}^N x_i y_i - \left(\sum_{i=1}^N x_i \right) \left(\sum_{i=1}^N y_i \right) / N$ $= 758.7075 \text{ mV} \cdot \text{N/cm}^2$
--	---	---

3. 计算出U、QL、QE、S

$$U = mbl_{xy}$$

$$Q_L = ml_{yy} - U$$

$$Q_E = \sum_{i=1}^n \sum_{j=1}^m (y_{ij} - \bar{y}_i)^2$$

$$S = U + Q_L + Q_E$$

计算表3 （重复实验时的方差分析表， n=11,m=4）

来源	平方和/(mV) ²	自由度	方差/(mV) ²	F		显著性
回归	$U = 20\ 932.257\ 4$	$\nu_U = 1$	20 932.257 4	F_1	5.65	显著
失拟	$Q_L = 0.138\ 6$	$\nu_{Q_L} = 9$	0.015 4	F_2	7.68×10^6	高度显著
误差	$Q_E = 0.089\ 9$	$\nu_{Q_E} = 33$	0.002 7			
残差	$Q = 0.228\ 5$	$\nu_Q = 42$	0.005 4	F	3.85×10^6	高度显著

4. 查 F_{α} 临界值表进行比较

根据计算表3中的 ν 值及 α 值查 F_{α} 临界值表得:

$$F_{0.01}(1,33) = 7.47$$

$$F_{0.01}(9,33) = 3.03$$

$$F_{0.01}(1,42) = 7.28$$

比较

$$F_1 = \frac{Q_L/\nu_{Q_L}}{Q_E/\nu_{Q_E}} = 5.65 > F_{0.01}(9,33) = 3.03$$

高度显著

$$F_2 = \frac{U/\nu_U}{Q_E/\nu_{Q_E}} = 7.68 \times 10^6 \gg F_{0.01}(1,33) = 7.47$$

高度显著

$$F = \frac{U/\nu_U}{Q/\nu_Q} = 3.85 \times 10^6 \gg F_{0.01}(1,42) = 7.28$$

高度显著

5. F检验的结果分析

比较 F 、 F_1 、 F_2 之值与所查得的 F_{α} 值可得出如下显著性结论。

(1) F_1 显著，说明失拟误差相对于试验误差来说是不可忽略的，所选择的一元线性回归这个数学模型与实际情况不符合，说明该直线拟合得并不好。即影响输出电压的除压力的一次方项之外，还可能存在高次方项的影响或者其他量的影响。

(2) F 和 F_2 均高度显著，说明试验误差和残余误差都很小，只要残余标准差 σ 小于该仪器所要求的精度参数，就可以使用此方程对该仪器进行定标。

当然，如有必要，可进一步查明原因，修改回归方程〔例如取 $y = b_0 + b_1x + b_2x^2$ 〕可能取得更好的 y - x 表达关系式。

§ 9-3 两个变量都有误差时回归分析

§ 9-4其他回归问题简介

在实践中，变量与变量之间的关系除线性相关外，大量存在非线性的统计相关。例如，激光测距仪的乘常数与气温、气压的关系就是非线性的。在解决非线性相关的问题时，可通过必要的变量转换，把非线性问题线性化。

在实际问题中，影响某一变量 y 的因素也常常不止一个，往往会是个。处理这类问题要用多元回归分析的方法。

前面介绍的回归方法，是一次性地利用全部测量数据计算回归系数。在动态测量中，数据往往是循序测出的，而且有的要求进行实时处理，即每获得一个新数据，就要及时解算出回归方程新的系数，采用递推算法是解决这一问题的最佳方法。

一、一元非线性回归 问题简介

在解决非线性相关的问题时，可通过必要的变量转换，把非线性问题线性化。为此，首先要正确地选择曲线类型，这是正确进行变量转换的前提。

曲线类型可以根据理论知识、专业经验选择。最常用的方法是根据实验数据作出“散点图”(称为相关图)，再将其与常见的典型曲线对比，从而选择曲线类型。选择曲线类型是比较困难的工作，有时要反复几次才能完成。

选好曲线后、可对其作线性化处理。

变量转换的方法大体有两种：一种是倒数法，另一种是对数转换法。

1. 常见曲线的线性化

(1). 双曲函数 $\frac{1}{y} = a + \frac{b}{x}$

令 $y' = \frac{1}{y}, \quad x' = \frac{1}{x}$

则可线性化为: $y' = a + bx'$

(2). 幂指数函数 $y = ax^b$

两边取对数, 得: $\lg y = \lg a + b \lg x$

令 $y' = \lg y, \quad a' = \lg a, \quad x' = \lg x$

则可线性化为: $y' = a' + bx'$

(3). S型曲线

$$y = \frac{1}{a + be^{-x}}$$

令 $y' = \frac{1}{y}, \quad x' = e^{-x}$

则可线性化为: $y' = a + bx'$

(4). 高次曲线

$$y = b_0 + b_1x + b_2x^2 + \cdots + b_mx^m$$

令 $x'_1 = x, \quad x'_2 = x^2, \cdots, \quad x'_m = x^m$

则可线性化为:

$$y = b_0 + b_1x'_1 + b_2x'_2 + \cdots + b_mx'_m$$

以上介绍了一些常用曲线的线性化方法。对于一些较复杂的曲线，还可采用泰勒级数展开取一次项的方法解决，也能取得一定效果。

曲线经过线性化后，确定回归系数仍可采用前面介绍的方法。不过，回归曲线求出后，要用原始变量代回原始回归方程中去，才能得出“真正的”回归方程。

2. 回归效果显著性检验

在非线性回归问题中，为表明所配曲线与实际观测数据间拟合的密切性，可定义

$$R = \sqrt{1 - \frac{Q}{S}}$$

式中S为总离差平方和，Q为残余平方和。

为了与原相关系数区别，可将R称为相关指数。它可作为检验回归效果的一种数量指标。

考虑到线性化后的模型与线性模型的差别，计算非线性回归方程的残余（误差）平方和Q时，必须根据实测数据 y_i 与由回归方程求得的 $\hat{y}_i$ 之差计算，而不能用 $y'_i - \hat{y}_i$ 计算总离差平方和S也只能根据原变量y计算。

R值的大小，可以用来衡量回归曲线效果的好坏，R越大(越是接近于1)，则表明所配曲线的效果越好，此外，检验回归效果也可用F检验法，或化为线性后的线性函数的相关系数。

必须指出，对非线性函数作线性化处理后，求回归系数使用的方法仍然是最小二乘法，即使 y' 的残余（误差）平方和达到最小。但这不能保证原变量非线性回归的误差平方和也达到最小值。例如，若曲线类型是双曲线。按最小二乘法，是使 $(\frac{1}{y_i} - \frac{1}{\hat{y}_i})^2$ 达到最小。所以不能说所配曲线，就是原变量关系间的最佳拟合曲线。因此，选配曲线时，最好能多选几种函数类型，计算后进行比较，择其最优者。

二、多元线性回归

前面讨论了两个变量之间试验结果的数学表示——一元回归问题，但在很多工程技术和科学实验的实际问题中，常常需要讨论多个变量之间试验结果的数学表示，这就是多元回归分析问题。

多元线性回归的原理与一元线性回归相同，但计算要复杂得多，往往要借助计算机才能完成。

1. 多元线性回归的数学模型式

$$Y = X\beta + \varepsilon \quad (9-70)$$

式中,

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \quad \beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_m \end{bmatrix} \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix} \quad X = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1m} \\ 1 & x_{21} & x_{22} & \cdots & x_{2m} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{nm} \end{bmatrix}$$

其中,

$(x_{t1}, x_{t2}, \dots, x_{tm}; y_t) \quad t = 1, 2, \dots, N$ 是通过试验得到N组观测数据:

y是因变量; x是M个可以精确测量或控制的一般变量;

$\beta_0, \beta_1, \beta_2, \dots, \beta_M$ 是M+1个待估计参数;

$\varepsilon_1, \varepsilon_2, \dots, \varepsilon_N$ 是N个相互独立且服从同一正态分布 $N(0, \sigma)$ 的随机变量。

2. 回归方程

设 $b_0, b_1, \dots, b_M$ 分别是参数 $\beta_0, \beta_1, \beta_2, \dots, \beta_M$ 的最小二乘估计, 则回归方程为

$$\hat{y} = b_0 + b_1 x_1 + \dots + b_m x_m \quad (9-71)$$

3. 正规方程

根据极值定理的正规方程组为

$$(X^T X)b = X^T Y \quad (9-74)$$

或

$$Cb = B \quad (9-75)$$

其中

$$C = X^T X \quad B = X^T Y$$

4.正规方程求解

设 $C=A^{-1}$ 为 A 的逆矩阵，在一般情况下(系数矩阵 A 满秩)它是存在的，于是正规方程的矩阵解为

$$b = C^{-1}B = (X^T X)^{-1}X^T Y \quad (9-76)$$

其中， X 是多元线性回归模型中数据 y_t 的结构矩阵，它构成 N 次试验；

A 是正规方程组的系数矩阵(亦称信息矩阵)；

C 是系数矩阵 A 的逆矩阵，亦称相关矩阵；

B 是正规方程组的常数项矩阵，它实际上是个列向量。

5. 回归方程的显著性和精度

与一元回归类似，多元线性回归也可以用数理统计检验的方法来检验。为此，要对多元线性回归进行方差分析。

其中，回归平方和 U 表示在 y 的总离差平方和中，变量 $x_1, x_2, \dots, x_M$ 与 y 的线性关系而引起 y 变化的部分，它的相应的自由度数为自变量的个数 M 。

y的总离差平方和S，回归平方和U和残余平方和Q的计算及其相应的自由度如表下所示。

来 源	平 方 和	自 由 度	方 差	F	显 著 性
回 归	$U = \sum_i (\hat{y}_i - \bar{y})^2$ $= \sum_{j=1}^M b_j l_{jy}$	M	$\frac{U}{M}$	$\frac{U/M}{\sigma^2}$	
残 余	$Q = \sum_i (y_i - \hat{y}_i)^2$ $= l_{yy} - U$	N - M - 1	$\sigma^2 = \frac{Q}{N - M - 1}$		
总 计	$S = \sum_i (y_i - \bar{y})^2 = l_{yy}$	N - 1			

显著性的检验与预报精度

回归方程显著性的检验可使用残余平方和对回归平方和的F检验进行

$$F = \frac{U/M}{Q/(N-M-1)} = \frac{U}{M\sigma^2}$$

多元回归方程的预报精度由残余标准差

$$\sigma = \sqrt{\frac{Q}{N-M-1}}$$

6. 自变量在多元回归中的影响分析

与一元线性回归问题不同，一个多元线性回归方程是显著的，并不意味着每个自变量 x_1 , x_2 , ..., x_M 对因变量 y 的影响都是重要的。

在实际应用中，我们希望能考察诸因素中哪些是影响 y 的主要因素，哪些是次要因素。

那么，如何来考察每个特定因素在总回归中所起的作用呢？

解决问题的基本思路

我们知道，回归平方和是所有自变量对y变差的总影响。所考察的自变量愈多，回归平方和就愈大。因此，若在所考察的因素中去掉一个因素，回归平方和只会减少，不会增加。减少的数值愈大，说明该因素在回归中起的作用愈大。也就是说该因素愈重要。

我们把取消一个自变量 x_i 后回归平方和减少的数值称为y对这个自变量 x_i 的偏回归平方和，记作 P_i 即

$$P_i = U - U'$$

式中 U —— M 个变量所引起的回归平方和；

U' ——去除 x_i 后的 $M-1$ 个变量后所引起的回归平方和。

因此，利用偏回归平方和 P_i 可以衡量每个自变量 x_i 在回归中所起作用的大小。

具体方法

由于各自变量之间可能有密切的相关关系，所以一般地不能按偏回归平方和的大小，把一个回归中的所有自变量对因变量y的重要性大小进行逐个排列。

通常在计算偏回归平方和以后，对各因素的分析可按如下步骤进行：

- ①用残余平方和Q对它进行F检验。此检验亦称回归系数显著性检验。
- ②重新建立M-1元的新的回归方程，计算回归系数及偏回归平方和，重新进行比较。

为此要计算统计量

$$F_i = \frac{P_i/1}{Q/(N-M-1)} = \frac{P_i}{\sigma^2}$$

变量的剔除

凡是偏回归平方和小的变量，并不一定不显著。但可以肯定，偏回归平方和最小的那个变量，必是所有变量中对 y 作用最小的一个，假如此时变量检验结果又不显著，那就可以将该变量剔除。

剔除一个变量后，得重新建立 $M-1$ 元的新的回归方程，计算回归系数及偏回归平方和，它们的大小一般都有所改变。

小结

以上介绍的内容是多元线性回归的基本方法，但多元回归不只是解决多元线性回归关系问题，还可以解决许多一元非线性和多元非线性关系问题。解决非线性关系的最一般方法是直接通过变量代换或者将非线性关系表示为(或展成)幂级数(多项式)，再通过变量代换转化为多元线性回归问题，这样就可以用多元线性回归方法来解决非线性回归问题。所以，多元线性回归是一种很有用的数据处理方法。但是，它有两个基本缺点：其一是计算比较复杂，其复杂程度随着自变量个数的增加而迅速增加；其二是回归系数间存在相关性，以至剔除一个自变量后，还必须重新计算。为避免这些缺点，对一般多元线性回归可采用回归的正交设计方法，对多项式回归可以利用正交多项式来配多项式回归的方法。还有一种直接获得“最优”回归方程的方法，这就是逐步回归分析方法。

本章结束!

Thank you !



谢谢!

